

Robustesse des Speech-LLMs face aux perturbations acoustiques et aux variations linguistiques

Une étude systématique de 4 modèles Whisper sur 3 langues

Safae Wardi

Master Big Data et Systèmes Intelligents

Université Sidi Mohamed Ben Abdellah, Fès, Maroc

<https://github.com/WardiSafae/speech-llm-robustness>

Septembre 2026

Abstract

Les Speech-LLMs (Whisper, Wav2Vec2, Qwen2-Audio) atteignent des performances remarquables sur des benchmarks standards, mais leur robustesse en conditions réelles — bruit urbain, réverbération, accents sous-représentés — reste insuffisamment caractérisée. Nous présentons la **première étude systématique** évaluant 4 modèles Whisper (base, small, medium, large-v3) sur 3 langues (anglais, français, arabe) et 4 perturbations acoustiques (bruit additif, réverbération, clipping, vitesse) à 3 niveaux de sévérité.

Nos résultats révèlent trois découvertes majeures : (1) whisper-large-v3 atteint un WER normalisé de 0.080 (contre 0.114 pour medium), mais **hallucine 47× plus** (237 contre 5 cas sur 3600) ; (2) la hiérarchie des perturbations est `reverb > white_noise > speed >> clipping` ; (3) le seuil critique d’hallucination est identifié à 25 mots. Nous proposons un détecteur d’hallucinations réutilisable en production et discutons les implications pour le déploiement des Speech-LLMs dans des applications critiques.

Mots-clés : Speech-LLMs, Whisper, robustesse acoustique, hallucinations, multilingue, évaluation systématique.

1 Introduction

1.1 Contexte

La reconnaissance automatique de la parole (ASR) a connu une transformation majeure avec l’avènement des modèles auto-supervisés (Wav2Vec2 [1], HuBERT [3], WavLM [4]) puis des modèles encodeur-décodeur à grande échelle (Whisper [5], Qwen2-Audio [6]). Ces derniers, souvent qualifiés de **Speech-LLMs**, combinent un encodeur acoustique avec un décodeur de langage, héritant des capacités des grands modèles de langage.

Whisper [5] a marqué une rupture avec **680 000 heures** d’audio multilingue, atteignant des performances élevées sur des benchmarks standards. Cependant, la **robustesse** de ces modèles en conditions réelles reste mal caractérisée.

1.2 Problème

Trois limitations majeures existent dans la littérature :

1. **Études mono-modèles** : la plupart des travaux évaluent un seul modèle.
2. **Études mono-dimension** : acoustique *ou* linguistique, rarement les deux.
3. **Absence d’analyse d’erreurs fine** : le WER moyen masque les cas extrêmes.

Question centrale : les modèles plus grands sont-ils *systématiquement* meilleurs ? Existe-t-il des *compromis cachés* ?

1.3 Contributions

Nos contributions sont les suivantes :

- **Benchmark exhaustif** : 4 modèles Whisper $\times$ 3 langues $\times$ 12 perturbations = **3600 évaluations**.
- **Analyse par langue** : révélation de disparités importantes (EN, FR, AR).
- **Découverte du paradoxe large-v3** : meilleur WER mais 47 $\times$ plus d'hallucinations.
- **Hiérarchie des perturbations** : reverb $>$ white_noise $>$ speed $\gg$ clipping.
- **Détecteur d'hallucinations** : utilisable en production (4/4 tests passés).
- **Seuil critique identifié** : 25 mots.

1.4 Plan

Le reste de l'article est organisé comme suit. La Section 2 présente l'état de l'art. La Section 3 décrit la méthodologie. La Section 4 présente les résultats. La Section 5 discute des implications. La Section 6 conclut et présente les travaux futurs.

2 État de l'art

2.1 Speech-LLMs

Wav2Vec2 [1] introduit l'apprentissage auto-supervisé sur des représentations audio. La variante **XL-SR-53** [2] l'étend à 53 langues. **Whisper** [5] est un modèle encodeur-décodeur entraîné sur 680 000 heures d'audio multilingue. Nous utilisons 4 variantes : base (74 M), small (244 M), medium (769 M), large-v3 (1.55 B).

2.2 Robustesse acoustique

La littérature distingue plusieurs familles de perturbations : bruit additif, réverbération, clipping, changements de vitesse, compression audio. **Koenecke et al.** [8] ont montré que Whisper **hallucine** sur silences et audios dégradés.

2.3 Accents et langues

Koenecke et al. [7] ont documenté un WER 2 $\times$ plus élevé pour les accents afro-américains. **Talafha et al.** [9, 10] ont évalué Whisper sur 15 dialectes arabes (WER 15–60 % selon le dialecte).

2.4 Augmentation et fine-tuning

Ko et al. [12] proposent la speed perturbation. **Park et al.** [13] introduisent SpecAugment. **Hu et al.** [14] proposent LoRA pour le fine-tuning param-efficace.

2.5 Lacunes identifiées

Notre projet comble 5 lacunes : peu d'études systématiques sur les Speech-LLMs récents (L1), benchmarks couvrant rarement acoustique *et* linguistique (L2), manque de pipelines reproductibles (L3), peu de travaux sur l'arabe (L4), analyse fine des erreurs souvent absente (L5).

3 Méthodologie

3.1 Datasets

Nous utilisons **FLEURS** [11], un benchmark multilingue standard. Le split *test* contient 100 échantillons par langue : **en_us**, **fr_fr**, **ar_eg**. Format : 16 kHz mono WAV.

3.2 Modèles évalués

Table 1: Modèles Whisper évalués

Modèle	Params	Hardware
whisper-base	74 M	CPU
whisper-small	244 M	CPU
whisper-medium	769 M	GPU T4
whisper-large-v3	1.55 B	GPU T4

3.3 Perturbations acoustiques

Table 2: Perturbations acoustiques et niveaux de sévérité

Perturbation	Sévérités	Technique
white_noise	5, 10, 15 dB	Bruit gaussien additif
reverb	0.1, 0.3, 0.5 s	Convolution IR
clipping	0.7, 0.5, 0.3	Saturation
speed	0.9, 1.0, 1.1	Time-stretch

Total : $4 \times 3 = 12$ conditions par audio, soit $300 \times 12 = \mathbf{3600}$ fichiers évalués.

3.4 Métriques

WER normalisé : lowercase + ponctuation retirée. **CER** : version caractère. **Latence** : temps d’inférence. **Taux d’hallucination** : proportion détectée.

3.5 Détecteur d’hallucinations

Nous proposons un détecteur basé sur 3 signaux :

1. **Longueur anormale** : $\text{len_ratio} = \frac{\text{hyp_len}}{\text{ref_len}}$, hallucination si $\text{len_ratio} > 1.5$ ou < 0.3 .
2. **Répétition** : token, bigramme, trigramme.
3. **Combinaisons** : longueur + répétition, ou $\text{hyp_len} > 50$.

4 Résultats

4.1 Baseline (conditions propres)

Observations : le saut de capacité est base $\rightarrow$ medium (0.30 $\rightarrow$ 0.11). L’arabe est débloqué par large-v3 (0.70 $\rightarrow$ 0.15).

Table 3: WER normalisé par langue (baseline)

Langue	base	small	medium	large-v3
EN	0.100	0.080	0.045	0.043
FR	0.300	0.150	0.090	0.060
AR	0.700	0.600	0.226	0.151
ALL	0.300	0.300	0.114	0.080

4.2 Robustesse par perturbation

Table 4: WER par perturbation (medium vs large-v3, ALL)

Perturbation	Sévérité	medium	large-v3	Δ
white_noise	snr5	0.340	0.231	−0.109
	snr10	0.218	0.151	−0.067
	snr15	0.193	0.113	−0.080
reverb	0.1	0.145	0.094	−0.052
	0.3	0.242	0.160	−0.082
	0.5	0.440	0.290	−0.150
clipping	0.3	0.124	0.083	−0.041
	0.5	0.114	0.079	−0.035
	0.7	0.115	0.081	−0.034
speed	0.9	0.251	0.170	−0.081
	1.0	0.114	0.080	−0.034
	1.1	0.303	0.200	−0.103

Hiérarchie : reverb > white_noise > speed $\gg$ clipping. Le clipping a un effet négligeable ($\Delta\text{WER} \approx 0$).

4.3 Découverte majeure : paradoxe large-v3

Table 5: Paradoxe : meilleur WER mais pire hallucinations

Métrique	medium	large-v3	Verdict
WER baseline (ALL)	0.114	0.080	large-v3 (−30 %)
WER perturbé max	8.68	1.50	large-v3 (−83 %)
Hallucinations	5 (0.14 %)	237 (6.6 %)	medium ($\times 47$)

Renversement : medium hallucine surtout sur FR ; large-v3 sur **EN**.

4.4 Seuil critique d'hallucination

Sur les 5 hallucinations de medium, les longueurs sont : {10, 15, 21, 22, 25} mots. Toutes surviennent sur des phrases > 10 mots. **Seuil recommandé** : 25 mots.

4.5 Détecteur d'hallucinations

4/4 tests passés.

Table 6: Hallucinations par langue

Langue	medium	large-v3	Δ
EN	0 (0.00 %)	120 (10.00 %)	+120
FR	5 (0.42 %)	68 (5.67 %)	+63
AR	0 (0.00 %)	49 (4.08 %)	+49
Total	5 (0.14 %)	237 (6.58 %)	+232 ($\times 47$)

Table 7: Tests du détecteur

Cas	Déecté	Confiance	Signal principal
fr_064 (massive)		0.62	len_ratio 8.84
fr_031 (milliers)		0.68	len_ratio 6.96
ar_000 ()		1.00	token_rep 1.00
Phrase normale	(non détectée)	0.0	Aucun

5 Discussion

5.1 Le paradoxe large-v3

Large-v3 est **meilleur en WER** mais **pire en hallucinations**. Nous interprétons cela comme “creative failure” vs “clean failure” : medium échoue *proprement* (troncatures), large-v3 échoue *créativement* (inventions grammaticales).

5.2 Le clipping est inoffensif

Découverte contre-intuitive : $\Delta\text{WER} \approx 0$ pour le clipping. Hypothèse : Whisper utilise des features Mel, invariantes aux changements d’amplitude globaux.

5.3 Déblocage de l’arabe

Large-v3 atteint 0.151 en arabe (vs 0.226 pour medium, ~ 0.70 pour base). Hypothèse : le seuil de capacité est autour de 500 M params.

5.4 Recommandations pour la production

Table 8: Choix du modèle selon le cas d’usage

Cas d’usage	Modèle	Justification
WER minimal	large-v3	30 % meilleur
Fiabilité	medium	$47\times$ moins d’hallucinations
Multilingue critique	medium	Hallucinations maîtrisées
WER + post-traitement	large-v3 + détecteur	Meilleur des deux
Temps réel	medium	Plus rapide sur CPU

5.5 Implications scientifiques

1. Le **scaling n’est pas monotone** : grand $\neq$ strictement meilleur.

2. **Le WER masque la distribution** : rapporter aussi les hallucinations.
3. **Les hallucinations sont spécifiques au modèle** : pas une propriété de la langue.

6 Conclusion et travaux futurs

6.1 Contributions rappelées

- Benchmark exhaustif : 4 modèles $\times$ 3 langues $\times$ 12 perturbations.
- Découverte du paradoxe large-v3 : meilleur WER mais 47 $\times$ plus d'hallucinations.
- Détecteur d'hallucinations production-ready.
- Hiérarchie des perturbations : reverb > white_noise > speed $\gg$ clipping.
- Seuil critique identifié : 25 mots.

6.2 Limitations

Whisper uniquement, FLEURS (dataset synthétique), pas de fine-tuning dans ce rapport.

6.3 Travaux futurs

1. Étendre à Wav2Vec2-XLSR-53 et Qwen2-Audio.
2. Analyse phonétique avec panphon.
3. Fine-tuning ciblé sur les cas difficiles (FR + reverb).
4. Soumission workshop ArabicNLP 2026 / Interspeech 2027.

Remerciements

Merci à OpenAI pour Whisper (open-source), à Google pour FLEURS (dataset), à Hugging Face pour Transformers, et à Google Colab pour le GPU T4 gratuit.

References

- [1] A. Baevski, Y. Zhou, A. Mohamed, and M. Auli, “wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations,” in *NeurIPS*, 2020.
- [2] A. Conneau, A. Baevski, R. Collobert, A. Mohamed, and M. Auli, “Unsupervised Cross-lingual Representation Learning for Speech Recognition,” in *Interspeech*, 2021.
- [3] W.-N. Hsu, B. Bolte, Y.-H. H. Tsai, et al., “HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units,” *IEEE/ACM TASLP*, 2021.
- [4] S. Chen, C. Wang, Z. Chen, et al., “WavLM: Large-Scale Self-Supervised Pre-Training for Full Stack Speech Processing,” *IEEE JSTSP*, 2022.
- [5] A. Radford, J. W. Kim, T. Xu, et al., “Robust Speech Recognition via Large-Scale Weak Supervision,” in *ICML*, 2023.
- [6] Y. Chu, J. Xu, X. Zhou, et al., “Qwen2-Audio Technical Report,” *arXiv:2407.10759*, 2024.

- [7] A. Koenecke, A. Nam, E. Lake, et al., “Racial Disparities in Automated Speech Recognition,” *PNAS*, 2020.
- [8] A. Koenecke, A. Choi, K. Mei, et al., “Careless Whisper: Speech-to-Text Hallucination Harms,” in *FAccT*, 2024.
- [9] B. Talafha, C. Chen, H. Sawaf, et al., “N-Shot Benchmarking of Whisper on Diverse Arabic Speech Recognition,” in *Interspeech*, 2023.
- [10] B. Talafha, A. Abu Alhassan, and M. Abdul-Mageed, “Zero-Shot Context-Aware ASR for Diverse Arabic Varieties,” in *Findings of ACL*, 2026.
- [11] A. Conneau, M. Ma, S. Khanuja, et al., “FLEURS: Few-Shot Learning Evaluation of Universal Representations of Speech,” in *SLT*, 2022.
- [12] T. Ko, V. Peddinti, D. Povey, and S. Khudanpur, “Audio Augmentation for Speech Recognition,” in *Interspeech*, 2015.
- [13] D. S. Park, W. Chan, Y. Zhang, et al., “SpecAugment: A Simple Data Augmentation Method for Automatic Speech Recognition,” in *Interspeech*, 2019.
- [14] E. J. Hu, Y. Shen, P. Wallis, et al., “LoRA: Low-Rank Adaptation of Large Language Models,” in *ICLR*, 2022.
- [15] J. Kaplan, S. McCandlish, T. Henighan, et al., “Scaling Laws for Neural Language Models,” *arXiv:2001.08361*, 2020.

A Reproductibilité

Tout le code est disponible sur GitHub : <https://github.com/WardiSafae/speech-llm-robustness>

```
git clone https://github.com/WardiSafae/speech-llm-robustness.git
cd speech-llm-robustness
python -m venv .venv && .venv\Scripts\activate
pip install -r requirements.txt
python scripts/smoke_test.py # 12/12 tests
```

B Tableaux complets

Voir `results/tables/fleurs/` pour les CSV détaillés.

C Figures

Voir `results/figures/` pour les graphiques (heatmaps, courbes, bar charts).